

昆曲 《寻梦》

音声与身体动作的跨模态同步性分析

视频来源：央视·顾卫英 演出《牡丹亭·寻梦》

时长：1494.3 秒（约 24.9 分钟）


分析日期：2026 年 4 月 4 日

核心发现

该演出中的 **音声-动作耦合** 发生在乐句层级 (**10–30 秒**)，而非节拍层级。

逐帧相关性接近于零 ($r < 0.03$)，但随着时间平滑窗口的增大，相关系数单调递增，在 30 秒窗口下达到 $r \approx 0.37$ 。


这与昆曲的美学特质一致——身段是写意的、表情性的，而非节拍驱动的。



图：多尺度包络相关性 —— 平滑窗口越大，音声与动作的相关性越强

分析管线概览

步骤	方法	输出
镜头切换检测	PySceneDetect (阈值 27)	检出 19 次切镜
音频特征提取	librosa: onset、RMS、pyin 基频、音高变化	64,360 帧 @ ~43fps
姿态估计	MediaPipe PoseLandmarker (重量级模型, 33 关节)	44,831 帧, 96.0% 有效检测
动作信号计算	身体中心坐标 + 尺度归一化速度 (肩部根节点)	7 个身体区域速度信号
信号对齐	重采样至统一 30fps 时间线	44,829 帧对齐信号



图：全部信号总览 —— 从上到下：音频 onset、RMS 能量、基频、全身运动、手部与躯干运动

数据质量

根节点模式对比


指标	髋部根节点	肩部根节点
运动 NaN 比例	34.3%	4.2%
手部 NaN	37.9%	13.8%
尺度参考 CV	0.363	0.469
有效帧数	29,467	42,948

关键信号 NaN 比例：

- 全身运动：4.2%
- 头部：4.2%
- 左手：20.3%
- 右手：27.7%（水袖遮挡）
- 基频（f0）：18.9%（无声段）

肩部模式大幅降低 NaN，有效数据量提升
46%。

以下所有分析均使用肩部根节点模式。



图：姿态检测质量 —— 上身关节有效率较高，下肢受画面裁切影响

逐帧分析：节拍层级无显著同步

Pearson 相关（音频 onset vs. 运动）


身体区域	r	p 值
上身	0.025	1.4e-05
躯干	0.015	1.7e-03
头部	0.012	1.0e-02
全身	0.012	1.6e-02
手部	0.012	2.0e-02

事件触发平均

提取 2,343 个显著 onset 峰值，对齐后取平均，动作信号 **无一致响应模式**。

表演者的身段并非逐拍响应音乐节奏——这是昆曲美学的特征，而非测量失败。

虽然 p 值显著（样本量大），但 **效应量可忽略不计** ($r < 0.03$)。



图：以音频 onset 峰值为基准的动作信号平均 (± 2 秒) —— 无明显峰值或谷值

多尺度包络相关性（核心结果）

将音频 onset 强度和运动速度分别以 0.5–30 秒窗口平滑，计算各尺度下的 Pearson 相关系数。

平滑窗口	全身	手部	躯干	头部
0.5 秒	0.053	0.052	0.050	0.053
2 秒	0.123	0.109	0.107	0.126
5 秒	0.183	0.171	0.151	0.187
10 秒	0.238	0.213	0.192	0.241
20 秒	0.306	0.292	0.250	0.308
30 秒	0.372	0.374	0.318	0.373

关键观察

- **头部**在各尺度一致领先——可能反映昆曲中头部标记乐句边界的传统
- **躯干**耦合最弱——作为体态的稳定锚点
- **手部**在长尺度追赶头部（30s 时 $r = 0.374$ ）——手势密度追踪音乐能量
- 相关系数在 30 秒处仍在增长——可能存在更大尺度的结构性耦合

非线性分析

互信息量 (MI) 与代理检验

互信息能够捕获 Pearson 相关无法检测的非线性依赖关系，通过 200 次时间打乱的代理信号评估显著性。


信号对	MI	代理均值	z 值	p 值
RMS 能量 vs 全身运动	0.0088	0.0044	15.18	<0.001 ***
音高变化 vs 头部运动	0.0044	0.0037	2.42	0.005 **
Onset vs 躯干	0.0048	0.0041	2.38	0.005 **
Onset vs 头部	0.0047	0.0042	2.02	0.025 *
Onset vs 全身	0.0045	0.0041	1.47	0.060

RMS vs 全身运动 ($z = 15.18$) 显示高度显著的非线性依赖——即使线性相关近乎为零。音声响度与动作之间可能存在阈值效应或情境调节的非线性关系。

音高变化 vs 头部运动 ($z = 2.42, p = 0.005$) 提供了旋律轮廓变化与头部运动关联的证据，与昆曲唱腔中头部标记声调转换的传统一致。

能量包络对比

RMS 能量包络 vs 运动包络 (5 秒平滑)




图：上——RMS 能量包络；中——运动包络；下——两者 z-score 归一化叠加对比

5 秒包络平滑下，RMS 能量与全身运动的线性相关 $r = -0.006$ （不显著）。但 onset 强度（强调节奏密度）与运动的相关显著高于 RMS（强调响度），表明 **表演者的动作密度追踪的是音乐的节奏活跃度，而非音量。**


时间变化与相机诊断

滑动窗口相关性 (10 秒)



相关系数在 $r = -0.3$ 到 $+0.5$ 之间波动，无固定时间模式。乐句层级耦合并非均匀，而是随戏剧与编舞情境而变化。

相机运动诊断



根节点位移和尺度参考分析。尺度 $CV = 0.469$ 反映了镜头推拉变化。

结论

1. 节拍层级无同步：逐帧 Pearson 相关 $r < 0.03$ ，事件触发平均无一致运动响应
2. 乐句层级显著耦合：10–30 秒包络下 $r = 0.24\text{--}0.37$ ，音乐密集段对应身体活跃段
3. 头部引领耦合层级：头部在所有时间尺度上相关性最高，其次手部、躯干最弱
4. 存在非线性依赖：互信息检验 RMS vs 运动 $z = 15.18$ ($p < 0.001$)
5. 旋律与头部动作关联：音高变化率 vs 头部运动 MI 显著 ($z = 2.42, p = 0.005$)

方法论启示

- **多尺度相关分析**是此类艺术形式最具信息量的单一分析方法
- 逐帧 Pearson 相关不适合作为昆曲的主要同步性指标——近零值反映的是时间尺度不匹配
- 肩部根节点模式显著优于腕部模式 (NaN: 4.2% vs 34.3%)

局限与展望

局限性

- **单一演出**：结论来自单一演员的单次录像，推广需更多样本
- **电视转播画面**：19 次切镜、变焦（ $CV = 0.469$ ）、上半身取景限制了提取质量
- **无唱词对齐**：缺乏音节级别的文本时间标注
- **手部遮挡**：右手 NaN 27.7%，受水袖遮挡影响
- **姿态模型局限**：MediaPipe 仅提供腕部级别手部追踪，无法分析手指细节

建议后续工作

1. 对不同演员的同一剧目进行多尺度分析对比
2. 整合唱词对齐数据，进行音节触发分析
3. 按戏剧功能分段（唱段/念白/做功），比较耦合特征
4. 使用 DWPose（133 关节）进行手势细节分析
5. 探索小波相干性，获取时频分解的耦合信息

谢谢

分析代码: `notebooks/exploration.ipynb`

完整报告: `reports/xunmeng_analysis.md`

分析管线: `src/run_all.py`